大语言模型在股票市场中的应用与挑战

邓湘雯

一、引言

股票市场是现代金融体系的核心，其运行效率与定价机制不仅是宏观经济景气度的晴雨表，更是连接资本配置与价值发现的关键纽带。从基本面分析到量化交易，从人工研判到算法决策，投资范式的演进始终与技术革新深度绑定。然而，当前市场环境下，数据复杂性、市场敏感性与实时分析需求、多样化投资策略与资产类别等痛点日益凸显：非结构化文本与多模态数据交织，远超人类分析师的处理能力，对传统分析框架构成挑战；高频交易与短期策略对毫秒级响应提出严苛要求，而复杂金融产品定价又需要深度分析；合规要求与创新压力并存 —— 在严监管环境下既要控制风险，又要寻找增长点；跨资产、跨市场的投资组合管理，也对模型的适应性与可扩展性提出了更高要求。

在这样的行业痛点下，大语言模型（LLM）凭借其对非结构化数据的强大处理能力、上下文理解与推理潜力，为突破上述瓶颈提供了全新可能。它不仅能将海量文本转化为可操作信号，更有望重塑从研究、决策到风险管理的全链条流程。但与此同时，LLM 在金融领域的落地实践中，也面临可解释性不足、训练数据存在偏差、实时性受限等核心挑战。本文将系统梳理 LLM 在股票市场中的具体应用，分析其底层技术与实践边界，探讨这一技术变革如何重塑投资生态，并展望其未来发展方向。

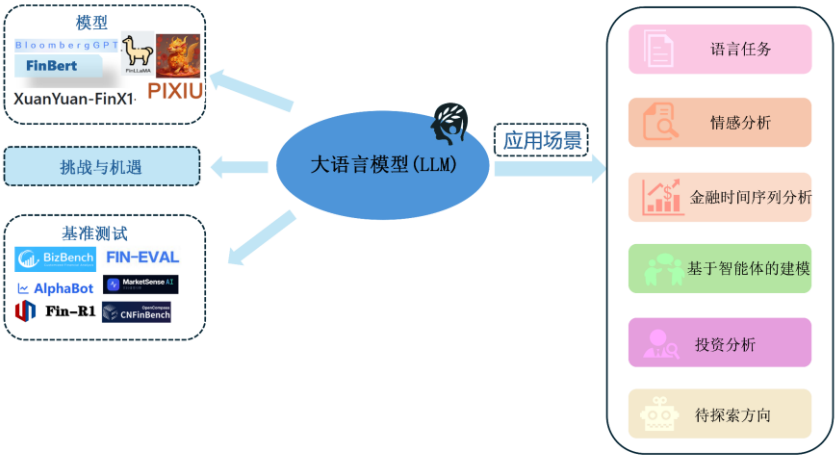

图 1：面向金融的大语言模型：综合应用框架

二、LLM 在股票市场的核心应用场景

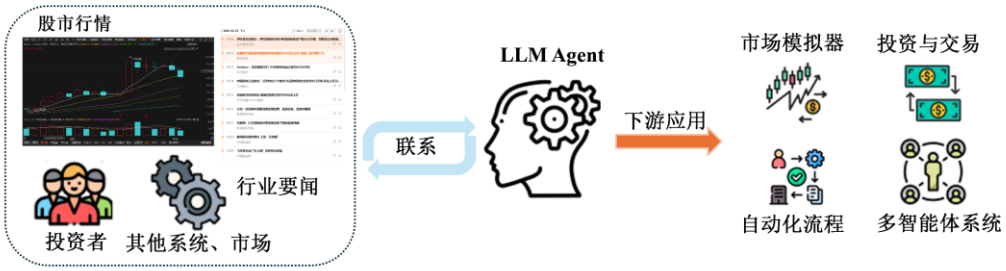

图 2：LLM Agent 在股票市场的应用架构图

（一）股票市场预测

在传统量化投资框架中，股票价格与市场趋势的预测高度依赖历史量价数据与财务指标的线性外推。然而，金融市场是海量信息与投资者情绪交织的非线性系统。LLM 的介入，重构了这一传统预测范式。当前，其应用逻辑主要体现在非结构化数据整合、投资者情绪挖掘，以及时间序列建模的改造三个方面。

LLM 的核心优势在于能够将宏观新闻、企业财报、分析师研报及社交媒体讨论等难以量化的非结构化文本，转化为可纳入量化策略的数字信号，实现了定性信息的量化整合。

表 1：卡特彼勒公司 2023 年第二季度财报电话会议话题相关性评分

总结后的问题	总结后的回答	语义余弦相似度
是什么推动了 3 亿美元的储备金增长？	价格和销量。	0.88
…	…	…
你们会在 2023 年下半年返还现金吗？	我们计划通过分红和股票回购的方式返还自由现金流。	0.73
卡特彼勒公司 2023 年第二季度财报电话会议平均话题相关性余弦相似度评分		0.80

（注：在财报电话会议结束后，卡特彼勒的每日股价上涨 9.2%，并在两周后维持了 7.3% 的涨幅。当高管就公司业绩和关键驱动因素提供透明、清晰的见解时，这能够增强投资者信心，进而推动股价积极调整）

在多源数据融合的探索中，研究人员正构建多引擎预测框架。例如，联合 GPT-4 与 BERT 模型可并行处理宏观经济指标与微观企业动态；端到端架构则能直接解析财务报表，将其转换为定量交易信号。为解决 AI 决策的 “黑箱” 问题，业界引入 Phoenix 等创新框架，将文本维度预测与数值指标整合进可解释体系。此外，融合多智能体与传统机器学习的上下文感知系统，进一步提升了预测的稳健性。这种跨模态融合不仅在全球市场表现优异，在 A 股市场的本土化应用中，也显著提升了价格预测的可靠性。

LLM 可以深度挖掘文本并量化投资者情绪。LLM 已经超越了传统的词典匹配与简单的情感分类，演进为深度的语义理解工具。对比通用 LLM 与金融垂直领域模型（如 FinBERT）的研究证实，大模型在处理商业新闻时，能精准捕获细微的情感特征与高维上下文关联，这是传统自然语言处理技术难以企及的。随着技术演进，情绪提取的颗粒度与适用边界不断拓宽，学术界与业界不仅开发了整合新闻情绪与价格信号的单任务交易模型，还涌现出 BioFinBERT（针对生物科技股）等垂直领域模型。Zhao and Welsch, 2024 引入的指令调整框架，通过结合实时市场反馈，将情绪分类的准确率和 F1 分数提升了 1% 到 6%。在美股等真实市场环境中，通用模型与领域特定模型的生成可靠性已得到充分检验 ——AlphaSense 的 NLP 引擎在 2024 年美股科技股回调中，提前 3 天预警恐慌情绪扩散，助力机构客户规避了 23 亿美元损失。

更关键的是，LLM 能够建立投资者情绪与股价走势的映射关系，形成可落地实践的情绪因子。Lefort et al.,2024 的实证研究表明，基于去趋势化累计情感分数构建的多空策略，在风险调整后收益上显著优于持有纳斯达克指数的被动基准；而未去趋势化的情感分数驱动策略则显著跑输基准，甚至成为表现最差的策略类别。

综上所述，大语言模型不仅拓宽了市场信息的获取来源，更通过自然语言解析与定性转定量的能力，提炼出隐藏在海量文本背后的情绪信号，为量化策略挖掘出了具有统计显著性的超额收益 Alpha 因子。

除文本处理外，LLM 的底层注意力机制正被改造，以适配金融市场的时间敏感性。研究者开始探索 LLM 在传统时间序列预测中的自回归潜力。Wang et al., 2024 提出的 StockTime 架构，创新性地将股票价格时间序列视为连续 “词元” ，直接从中提取相关性、统计趋势和时间戳等文本化信息，并与文本数据一同嵌入空间处理，实现了任意回溯期内的股价有效预测，同时提升了准确性并降低了成本。

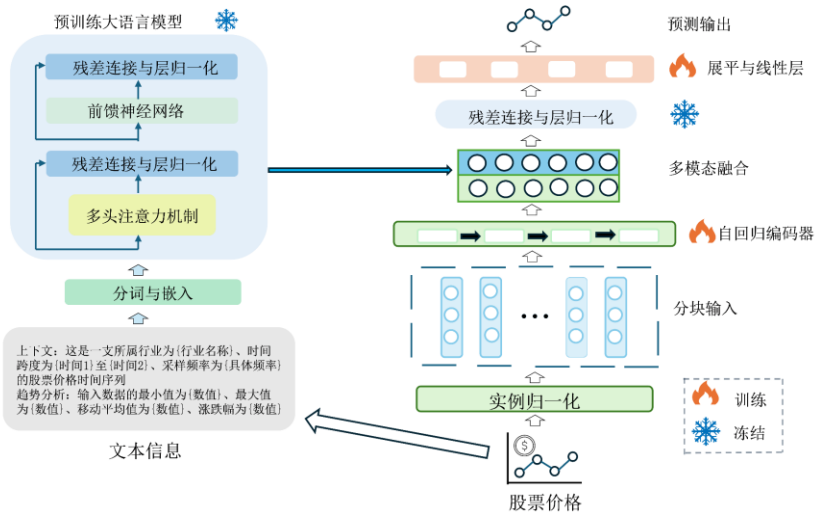

图 3：StockTime 框架的运行流程

该多模态金融预测模型以股票价格序列和文本信息（如行业名称、时间跨度、股价统计特征等）作为输入，先对股票价格进行实例归一化处理，再将文本信息通过分词与嵌入层转换为向量表示。随后，文本向量进入预训练大语言模型，依次经过多头注意力机制、前馈神经网络，并通过残差连接与层归一化进行特征提取与优化。同时，归一化后的股价序列作为分块输入，被送入自回归编码器进行时序特征建模，再与大语言模型输出的文本特征进行多模态融合。融合后的特征经过残差连接与层归一化后，由展平与线性层输出最终的预测结果；在训练过程中，可根据需求对部分模块进行训练或冻结，以适配不同的任务场景。

值得注意的是，Chen et al.，2024 发现，LLM 在预测短期股票收益时会表现出类人偏差，如 “趋势过度外推”与“乐观 / 悲观偏见”。具体而言，在持续时间较短的序列中，外推效应更显著；当信息以价格而非收益率形式呈现时，预测则趋于悲观。这些偏差具有场景依赖性，且难以通过人工干预纠正，这意味着在将 LLM 应用于金融预测时，必须充分理解并管控其内生的行为模式风险。

（二）自动化交易与决策系统

在完成了宏观价格预测与微观情绪感知后，量化投资的闭环最终指向交易执行。LLM 正推动自动化交易从基于静态规则的简单回应，向具备复杂认知与自适应能力的多智能体决策系统发生根本性演进。

首先是多智能体框架搭建交易决策链路。传统的自动化交易系统往往是单线程、规则驱动的相对刻板的响应，而基于 LLM 的多智能体框架（如 Trading-GPT），通过分层记忆机制与个性化交易特征建模，模拟了人类交易者在市场中的博弈与认知模式，从而提升了交易决策的准确性与执行效率。比如，银河证券以“小模型+大模型”的混合智能体架构，在处理

场外协商交易与做市服务等复杂场景时，展现出较强的场景适配能力。类似地， FinCon 与 StockAgent 框架已在真实的交易环境中实现从信号提取到投资组合管理的复杂链路闭环：Bybit TradeGPT 深度集成平台数据，提供实时市场简报、多空比、情绪指数、技术指标分析与回测，支持自然语言问答与自定义查询；其推出的 Telegram 机器人，还可向零售交易者与社群 KOL 推送交易信号与收益提醒。

其次是基于市场反馈的强化学习与自适应进化。在金融市场，唯一不变的就是变化，这种动态性导致传统量化策略容易出现性能衰减。为了打破这一瓶颈，学界和业界开始引入来自市场反馈的强化学习机制。这一机制赋予了 LLM 的自我迭代能力，使其能够根据真实市场的盈亏反馈动态调整自身的交易逻辑。这种自适应进化，是股权交易迈向自动驾驶式交易的关键一步。

最后是跨市场拓展与 AI 智能体平台的搭建。Yang et al.，2024 的研究开发了 FinRobot 这一新型开源 AI 代理平台，该平台支持多个金融专用 AI 代理，每个代理均由 LLM 驱动。具体而言，该平台由四个主要层组成：金融 AI 代理层，将复杂的金融问题分解为逻辑序列来构建金融思维链；金融 LLM 算法层，针对特定任务动态适配模型与应用策略；LLMOps 和 DataOps 层，通过微调技术和任务相关数据生成精确模型；多源 LLM 基础模型层，集成了各种 LLM 模型并直接访问这些模型。FinRobot 为专业分析师和普通用户提供了可落地的 AI 金融分析工具，显著降低了高级量化分析的实践门槛。

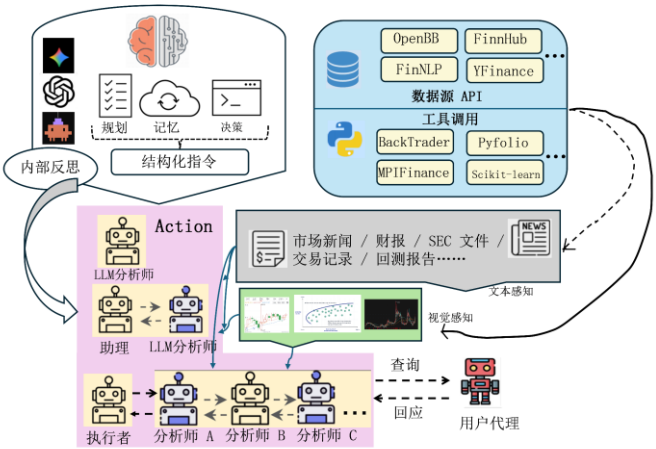

图 4：金融 AI 智能体协作工作流

图 4 展示了典型的 Finbot 工作流。用户通过用户代理发起查询后，核心大脑会通过规划、记忆与决策模块生成结构化指令；随后，核心大脑驱动多个大语言模型分析师及助理执行相应动作，并通过内部反思机制持续优化决策逻辑。同时，感知层通过数据源 API 和工具调用获取市场新闻、财报、交易记录等信息，形成文本与视觉感知；核心大脑进一步将文

本指令转换为参数和代码，驱动智能体团队完成金融分析任务，最终将分析结果反馈给用户。

（三）智能投顾与风险管理

在权益投资的完整闭环中，前端的收益预测与交易执行，最终需要后端的资产配置与风险控制来落地。LLM 的深度应用，正推动智能投顾与风险管理系统向主动适配、智能化的方向迈进。

在投资组合优化与机器理财顾问方面，L LM 展现出强大的动态调仓与再平衡能力。上海财经大学联合财跃星辰于 2025 年 3 月发布的 Fin-R1 模型，通过 “事件 - 影响 - 传导” 三层分析框架，将碎片化信息转化为连贯的投资逻辑。面对上市公司财报，Fin-R1 能自动执行 “历史数据清洗→会计政策调整→非经常性损益剥离→业务板块拆分” 的全流程，构建动态预测模型。Huang 等人，2024 推出的基于 LLM 的算法驱动系统，则进一步实现了股票初选与投资组合多元化构建的自动化。这表明，大语言模型已能辅助完成从资产筛选到组合构建的核心环节。

而在针对现实金融市场的大规模模拟测试中， Perlin 等人利用美国市场的大量数据评估了谷歌 Gemini 1.5 Flash LLM 的投资表现，发现其表现并不始终优于基本市场基准，且经风险调整后的收益会随着投资期限的延长而下降。这一发现揭示了 LLM 在理想模拟环境与真实市场之间的性能鸿沟，也为理论模型的落地提供了重要修正。

在面向个人投资者的机器人投顾应用中，LLM 不仅能够生成高度个性化的财务建议，研究者还开始关注投资者的金融知识水平（如对 Alpha 和 Beta 的认知）如何影响其对机器建议的接受度，这为财富管理的普惠化提供了有针对性的实践路径。

在风险管理与偏差评估维度，学术界开始系统审视 LLM 的稳健性与潜在风险。尽管多数研究狂热追逐预测的准确率，但在将 LLM 实际应用于股票预测时，模型容易陷入底层的数据陷阱。例如，Glasserman 和 Lin, 2023 指出 LLM 预测中常见的两种致命偏差：一是前瞻偏差，即 LLM 可能对新闻文章发布后的股票收益有特定的了解，错误混入了未来信息而非当前信息；二是分布外偏差，对所提及公司的普遍认知会干扰对文本情感的衡量，未来回报信息反向影响了当前资产预测。为此，他们提出的匿名化程序在样本外实施以及去偏回测中都可能发挥作用。这些底层的偏差评估，为金融机构安全部署大模型敲响了警钟。

三、LLM 的技术创新与方法

LLM 在股票市场的技术应用与创新，建立在系统调研与基准测试的基础之上。相关研究通过构建标准化评估框架、开展全领域应用梳理与技术拆解，为 LLM 在金融场景的落地明确了能力边界、性能基准与优化方向，也为各类技术方法的研发和实践提供了关键参考依据。本节结合前沿研究，从内部调优技术迭代与外部融合技术创新两个维度展开，逐层解析 LLM 赋能股票市场的核心技术路径与实践探索。

（一） 内部调优技术

1.提示工程

提示工程的逻辑在于通过结构化、策略化的输入设计，引导 LLM 完成金融文本理解、量化信号提取与投资决策推理。Dolphin 等人, 2024 结合了大语言模型生成能力与高级提示技术和验证框架，利用字符串相似度，从新闻文章中提取细粒度的、按公司划分的市场见解，证明了其高准确性，并提供了用于进一步研究的实时 API 和数据集。思维链提示进一步突破了复杂金融推理的瓶颈，Deng 等人, 2022 采用半监督方法，通过思维链提示引导大语言模型从 Reddit 帖子中生成弱情绪标签，再将这些标签蒸馏到一个使用回归损失的更小模型中，实现了与监督方法相当的性能。

2.微调

微调是通过数据训练实现模型参数定向优化的技术。为平衡股票市场的应用需求与算力成本，现有研究形成了全微调、指令微调、参数高效微调三大核心方向，并衍生出多技术融合的微调策略，在适配效果与落地效率上实现了双重提升。

全微调与领域适配是金融 LLM 打造的基础路径，通过在金融专属数据集上的完整训练，让模型深度捕捉股票市场的价格规律、行业特征与数据逻辑，适用于股票回报预测、行业赛道分析等核心任务。Guo 和 Hauptmann, 2024 针对股票回报预测任务对 LLM 开展全微调，通过整合不同模型架构的词级嵌入，强化了模型对金融数值特征的捕捉能力；Wang 等人, 2024 则开发出 InvestAlign 方法，通过构建合成监督微调数据集，让 LLM 投资决策与人类投资者行为更好对齐，减少认知偏差带来的决策失误，实现了全微调在实际投资场景的落地创新。

指令微调在领域适配的基础上进一步升级，通过融入金融特定任务指令构建训练数据集，引导模型学习股票市场的专业任务执行逻辑。Liang 等人, 2024 构建了专属的股票市场指令微调数据集，通过聚类公司相关新闻捕捉市场传播影响、为提示补充金融上下文与明确指令，再对 LLM 开展微调，显著增强了模型基于情感分析的股票走势预测能力。该策略让 LLM 能精准理解股票投资中的任务需求，成为连接通用模型与金融专业任务的桥梁。

而参数高效微调则解决了全微调节算成本高、部署难度大、易丢失通用能力的痛点，通过仅对模型部分参数进行更新，在轻量化训练的同时实现金融领域适配，成为当前股票市场 LLM 微调的主流方向。Konstantinidis 等人, 2024 在 Llama 2 7B 模型中实现 LoRA 微调，仅用 2.78M 参数就搭建出生成器 - 分类器架构，高效适配金融情感分析任务，为机器人咨询、股票情绪分析等场景提供了轻量化解决方案。

为进一步提升微调效果，现有研究还探索出多技术融合的微调策略，实现了性能与效率的双重优化。Ni 等人,2024 将 QLoRA 与指令微调结合，形成参数高效的指令微调策略，有

效改进了财报发布后的股票预测精度；Li 等人，2023 在 Llama2 上融合无监督与有监督 LoRA，并结合 GPT3.5 的指令微调，让模型可自动从各类金融文本中摘要、生成投资想法，大幅提升了基础投资研究效率。此外，微调还与知识迁移、嵌入生成深度结合。Das 等人，2024 利用大型预训练模型结合金融文本与价格信号开展微调，实现了模型知识向自动化交易行为的有效迁移，让微调技术成为 LLM 赋能股票投资全流程的核心支撑。

（二）外部融合技术

1.智能体框架

智能体框架是将 LLM 从单一语言模型升级为股票市场智能决策主体的关键技术。它通过赋予 LLM 自主决策、多主体协同与环境交互能力，使模型能够独立或协作完成股票研究、交易决策、异常检测等复杂金融任务。

基于思维链的多智能体系统通过多个专业化智能体的协同推理，模拟人类分析师的研究逻辑，解决单一智能体难以处理的复杂股票分析任务。Zhou,2024 搭建的多智能体思维链系统，设置了数据思维链、概念思维链、论点思维链三大专业化智能体，通过定量与定性分析的结合，实现了股票研究与估值的自动化完成。

基于协调网络的多智能体系统进一步强化了智能体间的交互与适配能力，覆盖股票投资全流程的多元化任务。Xiao 等人，2024 的 TradingAgents 分别通过角色化智能体协作、分层架构智能体设计，实现了交易决策模拟与复杂金融问题的拆解求解。

2.检索增强生成（RAG）

RAG 技术通过将 LLM 与外部金融知识库连接，使模型能够动态检索、整合实时且精准的金融信息，生成贴合市场最新情况的分析与决策结果，有效解决了 LLM 知识陈旧、信息片面的痛点，成为提升 LLM 股票市场应用准确性的关键技术。

现有研究中，RAG 技术已实现与 LLM 的深度融合：Li 等人，2024 提出的 AlphaFin 与 StockChain 框架，整合传统研究数据、实时金融数据与思维链数据，通过 RAG 技术构建两阶段金融分析流程，解决了金融训练数据集有限的问题，为 LLM 提供了丰富且实时的知识支撑。同时，RAG 技术还与零样本提示、智能体、强化学习等其他技术融合，形成复合型解决方案：Fatouros 等人，2025 的 MarketSenseAI 2.0 则将 RAG 与智能体框架融合，实现全维度的股票分析与选择。尽管目前将 RAG 作为核心技术的研究仍较少，但其为 LLM 注入的实时性与精准性，使其成为 LLM 赋能股票市场的重要技术方向。

3.强化学习（RL）

RL 与 LLM 的融合，使模型能够将股票市场的实时反馈作为奖励信号，不断优化自身的决策逻辑与输出策略，实现从静态分析到动态适配的转变。

Zhao, 2024 的分层强化交易员（HRT）框架，将强化学习与 RAG 技术结合，通过双深度强化学习提升模型可解释性，该框架在标普 500 指数的投资测试中，无论牛市、熊市还是波动市场，均实现了投资组合表现与风险管理的双重提升，验证了强化学习在 LLM 金融应用中的核心价值。强化学习与 LLM 融合打造出自适应与可解释的交易系统，也正逐渐成为股票市场实战应用的核心突破方向。

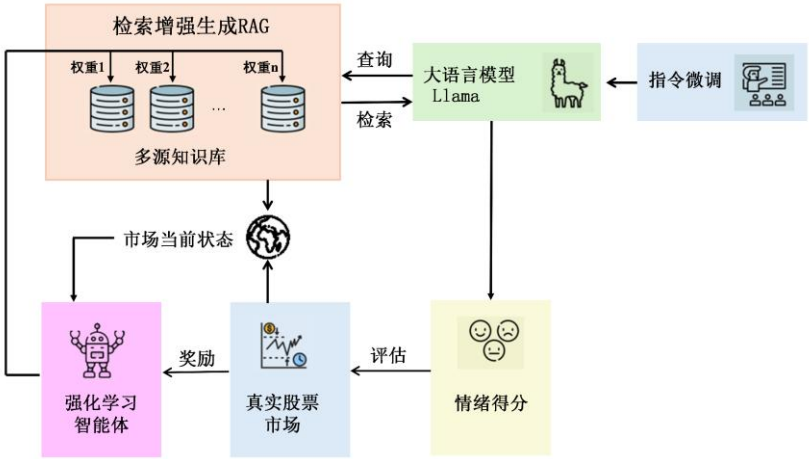

图 5：基于 RAG 与强化学习的 Llama 金融量化决策框架

经指令微调的 Llama 模型在接收用户查询后，向 RAG 模块发起检索请求；RAG 模块依据权重 1-n 从多源知识库中调取金融数据并将结果反馈至 Llama，随后 Llama 结合检索信息输出结论，生成情感得分并完成对真实股票市场状态的评估；最终，真实股票市场向强化学习智能体（RL Agent）反馈奖励信号，该智能体据此输出优化动作，反向更新 RAG 模块的检索权重与模型状态，从而构建起端到端的闭环优化体系。

4.基于嵌入的方法

基于嵌入的方法利用 LLM 强大的语义理解能力，将非结构化的金融文本转化为可量化、可计算的向量嵌入，不仅实现了文本信息的机器可读，还能捕捉文本中微妙的语言特征与复杂叙事。在投资者沟通评估等新兴任务中，嵌入方法也为研究开辟了全新的分析视角。

Chiang 等人，2025 从 192,000 个财报电话会议转录文本中提取 LLM 向量嵌入，通过量化问答环节的语义对齐度与相关性，构建了评估投资者沟通有效性的全新指标，让市场能够更深入地理解财报电话会议中的信息传递价值，为上市公司价值分析与投资决策提供了新的参考维度。基于嵌入的方法，实现了金融文本信息的深度挖掘与量化应用，成为连接非结构化文本与投研分析的重要桥梁。

四、LLM 在股票市场应用中的挑战

通过金融数据微调与领域预训练，LLM 已形成一批专业化工具。在通用基础模型的金融适配方面，BloombergGPT 基于 BLOOM 架构完成通用与金融语料的大规模预训练，在新闻信息提取与舆情监控任务中表现突出；FinGPT 采用轻量级 LoRA 微调技术，支持多基础模型适配，可低成本实现金融数据集处理与市场情绪分析；InvestLM 则在 LLaMA 基座上结合精选投资数据微调与强化学习，聚焦复杂投资策略生成与量化交易辅助。

以 LLaMA 与 BERT 为代表的专用基础衍生模型同样形成了技术矩阵。FinLaMA、FinLlama 及 FinMA（PIXIUI）均基于 LLaMA 完成金融语料预训练与指令微调，其中 FinLlama（7B）凭借轻量化设计更适配算法交易的情感分析场景，FinMA 则提供 7B/70B 多版本以匹配不同算力需求；FinBERT 基于 BERT 框架采用多任务学习范式，是金融 NLP 任务的经典基线，具备良好的可解释性；FLANG 则专注于金融语料深度理解，支持定制化金融文本处理任务。

表 2：股票投资领域主要的金融大语言模型概览

模型名称	基础模型	参数规模	专业方向	关键特性
BloombergGPT	BLOOM	~50B	金融文本	在通用及金融语料上训练；在新闻类任务中表现较好
FinGPT	Various	Varies	金融数据	采用 LoRA 微调；具备传播感知和上下文增强能力
InvestLM	LLaMA	65B	金融投资	在精选投资相关应用数据集上微调；聚焦高级强化学习集成
FinLaMA	LLaMA-2	52B	金融情感分类	在金融语料上预训练，并用金融指令进行指令微调
FinLlama	LLaMA-2	7B	算法交易的情感分析	针对情感分类的 valence 和 strength 进行微调；
FinMA (PIXIU)	LLaMA	7B, 70B	金融情感分析与 NLP 任务	在金融数据集上微调
FinBERT	BERT	N/A	金融 NLP 任务	在通用和金融语料上预训练；采用多任务学习
FLANG	Custom	N/A	金融语料	领域专属模型

尽管上述模型的核心能力体现在对研报、新闻、公告等非结构化数据的高效解析上。它们能够将市场情绪转化为可量化的交易因子，显著降低了金融 AI 应用的开发门槛，但其在股票市场的落地应用仍面临来自学界与业界的多重挑战，这些挑战不仅限制了技术的普及，也深刻影响着投资决策的可靠性与可扩展性。

在学界，LLM 在股票投资领域的研究仍受限于三大核心瓶颈：

1.真实场景验证缺失：多数研究仅在受控环境中完成验证，对真实交易中的滑点、交易成本、市场冲击等关键因素缺乏考虑，导致研究结论与实战脱节。

2.数据质量与偏差问题：LLM 对训练数据高度敏感，而市场实时数据与非结构化文本本身易携带偏见、误导性信息甚至操纵痕迹，贯穿研究全流程。

3.可解释性缺失：多数基于 LLM 的模型具有 “黑箱” 特性，且主流 GPT-based 闭源模型未开放规格细节，导致投资者与监管机构难以验证决策合理性。同时，研究区域集中于中美市场，资产类别聚焦于股票长期价值投资，对日内交易、高频策略及大宗商品、固定收益等非股票领域的探索不足。

相较于学界的理论瓶颈，业界实践面临的挑战更贴合真实交易的严苛约束：

1.交易成本与时效性限制：回测中表现优异的策略，易因实盘频繁调仓产生高额手续费与市场冲击，导致收益大幅缩水；而 LLM 推理的高耗时特性，使其无法适配高频交易的毫秒级响应需求，仅能应用于基本面分析、事件驱动等中低频场景。

2.极端事件下的稳健性不足：在金融危机、政策突变等“黑天鹅”事件中，LLM 缺乏有效的应对机制，难以应对市场范式的突然转换，稳健性远逊于传统均值回归等策略。

3.数据与模型可靠性风险：LLM 的“幻觉”问题成为致命短板，其可能编造虚假财务数据、分析师报告等信息，微小事实错误即可引发巨额投资损失，倒逼机构建立严格的人工复核机制；同时，数据的实时性偏差与模型的确认偏差，易加剧策略过拟合风险，而同质化的数据源与模型架构则可能进一步引发 “算法羊群效应”，导致市场踩踏与策略失效。

4.应用场景与人才供给限制：当前 LLM 应用集中于股票投研领域，向大宗商品、期权等复杂资产类别的适配成本极高；而既懂金融投资又掌握 AI 技术的复合型人才稀缺，成为制约技术规模化落地的关键瓶颈。

总体而言，当前阶段的 LLM 在股票市场中更适合扮演投研助手的角色，其核心价值在于提升信息处理与分析效率，而非作为独立的交易决策者。唯有将 LLM 与严格的风控体系、人工复核机制及传统量化框架深度结合，才能有效规避技术与市场风险，实现其在股票投资领域的稳健应用。

五、尾声

大语言模型为股票市场突破数据处理、决策效率等行业痛点提供了全新路径，其在市场预测、自动化交易、智能投顾等场景的应用，以及内部调优与外部融合的技术创新，正推动投资生态向智能化演进。诚然，LLM 的落地仍面临数据偏差、可解释性不足、实盘时效性受限等诸多挑战，且当下技术探索多解决即时痛点，对远期技术风险缺乏绝对预判力。但接受这种不确定性，正是金融技术创新的勇气所在。发展 LLM 的金融应用，更需要前进的智慧，既要清醒认知技术边界，也要持续推进技术融合与人才建设。唯有勇探新径、善解难题，让大语言模型与股票市场深度适配，才能真正释放其技术价值，为市场发展注入持久动能。

［参考文献］

[1] Aparicio, V., Gordon, D., Huayamares, S. G., & Luo, Y. (2024). BioFinBERT: Finetuning large language models (llms) to analyze sentiment of press releases and financial text around inflection points of biotech stocks. *ArXiv*. https://arxiv.org/abs/2401.11011

[2] Chen, S., Green, T. C., Gulen, H., & Zhou, D. (2024). What does ChatGPT make of historical stock returns? Extrapolation and miscalibration in LLM stock return forecasts. https://ssrn.com/abstract=4941906

[3] Chiang, H., Hynes, L., & Sandberg, D. (2025). Questioning the answers: LLMs enter the boardroom. *S&P Global Market Intelligence Quantamental Report*. https://ssrn.com/abstract=5109196

[4] Das, S., Zera, R. E., Lyngkhoi, M., Saha, S., & Maurya, A. (2024). Wealth guide: A sophisticated language model solution for financial trading decisions. In *Proceedings of the Eighth Financial Technology and Natural Language Processing and the 1st Agent AI for Scenario Planning* (pp. 133–140), Jeju, South Korea.

[5] Ding, Y., Jia, S., Ma, T., Mao, B., Zhou, X., Li, L., et al. (2023). Integrating stock features and global information via large language models for enhanced stock return prediction. *ArXiv*. https://arxiv.org/abs/2310.05627

[6] Dolphin, R., Dursun, J., Chow, J., Blankenship, J., Adams, K., & Pike, Q. (2024). Extracting structured insights from financial news: An augmented LLM driven approach [Preprint]. *ArXiv*. https://arxiv.org/abs/2407.15788

[7] Fatouros, G., Metaxas, K., Soldatos, J., & Karathanassis, M. (2025). MarketSenseAI 2.0: Enhancing stock analysis through LLM agents. *ArXiv*. https://arxiv.org/abs/2502.00415

[8] Glasserman, P., & Lin, C. (2023). Assessing look-ahead bias in stock return predictions generated by GPT sentiment analysis. *ArXiv*. https://arxiv.org/abs/2309.17322

[9] Gu, J., Ye, J., Wang, G., & Yin, W. (2024). Adaptive and explainable margin trading via large language models on portfolio management. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF '24)* (pp. 248–256).

[10] Guo, T., & Hauptmann, E. (2024). Fine-tuning large language models for stock return prediction using newsflow. In *Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing: Industry Track* (pp. 1028–1045), Miami, Florida, US. Association for Computational Linguistics.

[11] Huang, Z., Zhang, Z., Hua, C., Liao, B., & Li, S. (2024). Leveraging enhanced egret swarm optimization algorithm and artificial intelligence-driven prompt strategies for portfolio selection. *Scientific Reports*, 14, 26681. https://doi.org/10.1038/s41598-024-77925-2

[12] Kong, Y., Nie, Y., Dong, X., Mulvey, J., Poor, V., Wen, W., et al. (2024). Large language models for financial and investment management: Applications and benchmarks. *The Journal of Portfolio Management: Quantitative Tools*, 51, 162–210. https://doi.org/10.3905/jpm.2024.1.645

[13] Konstantinidis, T., Iacovides, G., Xu, M., Constantinides, T. G., & Mandic, D. (2024). FinLlama: Financial sentiment classification for algorithmic trading applications. In *Proceedings of the 5th ACM International Conference on AI in Finance (ICAIF '24)* (pp. 134–141).

[14] Lefort, B., Benhamou, E., Ohana, J.-J., Saltiel, D., Guez, B., & Jacquot, T. (2024). Sentiment analysis of bloomberg markets wrap using ChatGPT: Application to the NASDAQ. https://ssrn.com/abstract=4780150

[15] Li, Y., Yu, Y., Li, H., Chen, Z., & Khashanah, K. (2023). TradingGPT: Multi-agent system with layered memory and distinct characters for enhanced financial trading performance [Preprint]. *ArXiv*. https://arxiv.org/abs/2309.03736

[16] Li, Y., Luo, B., Wang, Q., Chen, N., Liu, X., & He, B. (2024). CryptoTrade: A reflective LLM-based agent to guide zero-shot cryptocurrency trading. In *Proceedings of EMNLP 2024* (pp. 1094–1106). Association for Computational Linguistics.

[17] Liang, Y., Liu, Y., Zhang, B., Wang, C. D., & Yang, H. (2024). FinGPT: Enhancing sentiment-based stock movement prediction with dissemination-aware and context enriched LLMs. *ArXiv*. https://arxiv.org/abs/2412.10823

[18] Liu, C., Arulappan, A., Naha, R., Mahanti, A., Kamruzzaman, J., & Ra, I. H. (2024). Large language models and sentiment analysis in financial markets: A review, datasets, and case study. *IEEE Access*, 12, 134041–134061. https://doi.org/10.1109/ACCESS.2024.3445413

[19] Perlin, M., Foguesatto, C., Muller, F. M., & Righi, M. (n.d.). Can AI beat a naive portfolio? An experiment with anonymized data. https://ssrn.com/abstract=4954881

[20] Saqur, R., & Rudzicz, F. (2024). Stock price trend prediction using emotion analysis of financial headlines with distilled LLM model. *Open Review*.

Tandon, R. (2024). Prediction of stock market trends based on large language models. *ITEGAM Journal of Engineering, Technology, and Industrial Applications (ITEGAM-JETIA)*, 11, a615–a622. https://www.jetir.org/view?paper=JETIR2409071

[21] Wang, H., Pan, Z., Zhang, H., Liu, M., Lin, Y., & Zhao, H. V. (2024). InvestAlign: Align LLMs with investor decision-making under herd behavior. In *Adaptive Foundation Models: Evolving AI for Personalized and Efficient Learning (NeurIPS 2024)*.

[22] Wang, S., Ji, T., Wang, L., Sun, Y., Liu, S., Kumar, A., et al. (2024). StockTime: A time series specialized large language model architecture for stock price prediction. *ArXiv*. https://arxiv.org/abs/2409.08281

[23] Yang, H., Zhang, B., Wang, N., Guo, C., Zhang, X., Lin, L., et al. (2024). FinRobot: An open-source AI agent platform for financial applications using large language models. *ArXiv*. https://arxiv.org/abs/2405.14767

[24] Zhao, H., Liu, Z., Wu, Z., Li, Y., Yang, T., Shu, P., et al. (2024). Revolutionizing finance with LLMs: An overview of applications and insights [Preprint]. *ArXiv*. https://arxiv.org/abs/2401.11641

[25] Zhao, Z., & Welsch, R. E. (2024). Aligning LLMs with human instructions and stock market feedback in financial sentiment analysis. *ArXiv*. https://arxiv.org/abs/2410.14926

[26] Zhao, Z. (2024). Next-generation intelligent portfolio management [Institutional report]. Cambridge, MA: Massachusetts Institute of Technology. https://dspace.mit.edu/handle/1721.1/156635

[27] Zhou, T., Wang, P., Wu, Y., & Yang, H. (2024). FinRobot: AI agent for equity research and valuation with large language models. *ArXiv*. https://arxiv.org/abs/2411.08804